

MOI EVALOPS

企业 AI 的持续验证 与质量运营平台

让 Document、RAG、NL2SQL、Memory 与 Agent
从“可以演示”走向“可验收、可追溯、可持续改进”

业务验收

持续评测

质量门禁

证据审计

私有化运行

企业 AI 的挑战，正从“构建能力”转向“持续证明能力”

01

效果难定义

不同业务对“正确”的定义不同，通用榜单无法替代客户验收。

02

结果难复现

模型、Prompt、数据和平台持续变化，同一问题可能得到不同结果。

03

失败难定位

解析、检索、语义、Agent 编排和工具执行相互影响，单一总分无法说明根因。

04

质量难持续

POC 有效果，不等于每次升级都能保持效果；人工抽查也无法覆盖长尾风险。

企业需要的不是“再跑一次分”，而是每次升级都能被验证的质量闭环。

让每一个 AI 能力都有可执行的验收标准



验

可验收

把业务语言转化为数据集、Golden、指标和通过条件。

溯

可追溯

每个结果追溯到数据、模型、配置、版本与原始证据。

续

可持续

历史 badcase 自动进入回归资产，阻止同类问题再次进入生产。

EvalOps 是企业 AI 全生命周期的质量工程体系

组成	核心内容	客户价值
方法论	场景拆解、指标设计、Golden 规范、可比性规则	“测什么、怎么算”有统一口径
评测资产	数据集、任务、Golden、badcase、基线、行业模板	项目经验持续沉淀与复用
工具平台	自动运行、评测、对比、门禁、报告、证据导出	降低重复测试和人工分析成本
运营机制	版本回归、失败复盘、质量看板、发布策略	把质量管理变成持续过程
AI Copilot	Golden 辅助生成、用例扩展、错误聚类、报告生成	加速资产建设与问题定位

EvalOps 不是一次跑分，而是一套持续运转的 AI 质量操作系统。

覆盖企业 AI 的五大能力域

D

Document

文本、标题、表格、公式、图片、阅读顺序、版面与 Excel 专项。

R

RAG

检索命中、证据覆盖、忠实度、完整性、引用与拒答。

S

NL2SQL

Schema 理解、SQL 生成、执行结果、业务语义、稳定性与时效。

M

Memory

写入、检索、更新、版本、分支、回滚、治理与长期记忆。

A

Agent

任务完成、工具调用、轨迹、预算、超时、恢复与安全边界。

统一原则： 优先验证真实任务结果， 而不是只让另一个大模型判断“看起来是否正确”。

MOI EvalOps 能力架构



从“一个总分”升级为“可行动的诊断”

传统评测通常只能回答

得了
多少分？

哪个场景、哪类数据、哪一步开始退化？

问题来自模型、业务语义、检索、解析还是 Agent 编排？

新版本改进了什么，又引入了什么？

是否满足发布条件，结论能否重新验证？

评测的终点不是报告，而是下一步可执行的优化决策。

阶段性评测证据与系统价值

业务语义可量化

+20 pp

口语化业务问题严格正确率

62.67% → 82.67%
全量严格正确率 76.67% → 86.67%
Enron Eval 50 · 50 题 × 3 轮

复杂企业文档

42 / 50

本次三方对比中取得最高结果

0 个有效解析失败
长文档、Office、跨页表格与公式

可治理长期记忆

91.80%

LongMemEval-S 本地评测

459/500 · 500 题
快照回滚 50/50 · 低置信治理 50/50
分支、Diff 与 Merge 48/50

证据索引：Enron Eval 50、复杂制造业文档私有集、LongMemEval-S、Memoria Feature 自建集。结果仅代表固定版本与相应测试集；详细 Run/Report 可按项目提供。

面向客户的三类交付方案

A

AI 能力验收

适用于 POC、产品选型和项目交付。

场景清单 · 测试集 · Golden · 指标口径 · 运行结果 · 验收报告

B

持续质量回归

适用于模型、Prompt、知识库或产品频繁升级的生产系统。

Baseline · 自动回归 · 趋势分析 · 退化告警 · 发布门禁

C

AI 质量运营

适用于多应用、多团队和多模型的企业级 AI 平台。

统一资产目录 · 质量看板 · 问题闭环 · Evidence Bundle · 周期报告

从售前验证到生产运营，使用同一套数据、指标、证据和质量语言。

三个可快速启动的场景包

文

企业文档与知识问答

文档 → 解析 → 索引 → 检索 → 回答 → 引用验收

重点：复杂格式、证据覆盖、忠实度与可追溯引用

数

业务数据库智能问数

自然语言 → 语义理解 → SQL → 执行 → 结果集验收

重点：业务术语、执行正确率、复杂查询、稳定性与时延

智

企业 Agent 任务执行

任务 → 计划 → 工具调用 → 执行轨迹 → 结果验收

重点：完成率、预算、超时、失败恢复与安全边界



一套可信、可复现的评测过程

标准化 Run 固化

- Dataset / Task / Golden 版本
- 系统、模型、Provider 与 Prompt
- 配置、环境、Evaluator 与聚合算法
- 逐题结果、失败分类和原始工件
- 性能、Token、关键轨迹与运行时间

Evidence Bundle

- 运行摘要与版本清单
- 逐题证据和失败分类
- 原始产物索引与 Hash
- 脱敏后的客户审计报告
- 可由客户或第三方复核

可比性保护

当数据、维度、权重、格式或聚合口径不一致时，不直接生成具有误导性的单值差异。

从统一评测走向企业 AI 质量运营

CURRENT

评测资产与项目交付

- 五域方法与评测资产
- 私有数据集与 Golden
- 在线与离线接入
- 逐题诊断与版本对比
- 证据化评测报告

NEXT

持续质量门禁

- 标准化 Run / Baseline / Gate
- Evidence Bundle 自动生成
- CI/CD 与定时回归
- P95/P99、成本与安全门禁
- 生产 badcase 自动回流

EVOLVE

企业质量运营平台

- 多项目质量看板
- 行业 Starter Kit
- AI Golden 与测试生成
- 客户见证运行
- 第三方复核机制

当前能力按项目范围接入；标准化 Gate、Evidence Bundle 自动化与控制台按路线推进。

为什么选择 MOI

链

验证真实产品链路

覆盖解析、检索、语义层、Agent 编排、工具执行与最终结果。

证

给出证据与根因

结果可回溯到样本、步骤、配置、版本和原始工件。

资

沉淀持续质量资产

每次项目、升级和生产问题都会转化为新的回归能力。

验

行业可执行验收

把客户业务规则转化为 Golden、Verifier 和发布门禁。

让企业 AI 的每一次升级，都建立在可验证的进步之上。

START WITH ONE REAL SCENARIO

从一个真实场景 建立首个质量基线

选择一个高价值 AI 场景，快速形成可验收、可诊断、可持续回归的质量闭环。

1 对齐业务目标和验收口径

2 建立代表性数据集与 Golden

3 完成 Baseline 运行与问题诊断

4 形成优化建议与持续回归机制

MOI EvalOps